



Exploring new tendencias in numerical optimization applied to PINNs. An example with the nonlinear time-dependent Schrödinger's Equation.



Cruz, Díaz Emmanuel ¹ Velazquez, Castro Jorge ²

^{1,2}Facultad de Ciencias Físico Matemáticas, Benemérita Universidad Autónoma de Puebla

Abstract

Recientemente las *Physics Informed Neural Networks (PINN)* han surgido como una alternativa muy poderosa para la resolución de problemas numéricos directos e inversos. Empero, el estado del arte del diseño de las PINNs se ha visto estancado en el uso de optimizadores como Adam o SGD junto con optimizadores quasi-Newtonianos como el LBFGS. Este trabajo explora las nuevas tendencias en optimización numérica, típicamente empleadas en modelos largos de lenguaje (LLM) y una propuesta de optimizador LBFGSAdam que aprovecha lo mejor de ambos optimizadores. El problema atacado para explorar estas nuevas tendencias en optimización es la ecuación de Schrödinger no lineal dependiente del tiempo. Los resultados muestran que estas nuevas alternativas para optimizar la función de costo de las PINNs son favorables y que estos optimizadores permiten obtener una mayor precisión que el estado de arte actual de las PINNs, muy a pesar de que su diseño no haya sido precisamente enfocado para este propósito.

Physics Informed Neural Networks

Las redes neuronales informadas de la física (PINN) resultaron como una propuesta para la resolución de problemas directos e inversos que involucran ecuaciones diferenciales ordinarias o parciales lineales o no lineales. Este método aprovecha que las redes neuronales profundas son aproximadoras universales de funciones [4] y la diferenciación automática con la que estas funcionan, diferenciando a la red respecto a sus entradas y sus parámetros. Las PINNs permiten además aplicar constricciones al modelo de manera que la solución respete cualquier simetría, invariancia o principios de conservación que se origine de cualquier ley de la física que gobierne al problema en cuestión, dado que el mismo esté modelado por alguna ecuación diferencial parcial dependiente o no dependiente del tiempo [7].

Una tarea de modelado busca entender el comportamiento de un sistema desde una perspectiva científica y obtener características que describan al sistema de forma general. Así, en el caso de las PINNs, existen dos tipos principales de problemas: Directos e inversos.

Los problemas directos son aquellos cuya solución da una relación entre los parámetros x utilizados para describir el modelo.

Research gaps

si

Muon

El optimizador muon es un optimizador especialmente diseñado para capas ocultas de redes neuronales lineales introducido por primera vez por

LBFGSAdam

Este optimizador fue diseñado por

LBFGS

El optimizador Limited-memory BFGS es un algoritmo de optimización quasi-Newtoniano que

Multi-scale Momentum Muon M3

El optimizador M3 es resultado de los últimos trabajos del equipo de Google Research como una propuesta para aplicar su nuevo paradigma de aprendizaje de máquina, memoria continua y Nested Learning.

Ecuación de Schrödinger no lineal

Conclusiones

sí

Referencias

[1] Ali Behrouz, Meisam Razaviyayn, Peilin Zhong, and Vahab Mirrokni. Nested learning: The illusion of deep learning architecture. Technical report, Google Research, 2025.

[2] Saverio Cambioni, Erik Asphaug, and Roberto Furfaro. Combining machine-learned regression models with bayesian inference to interpret remote sensing data. *Machine Learning for Planetary Science*, pages 193–207, 1 2022.

[3] Wojciech Deębski. Probabilistic inverse theory. *Advances in Geophysics*, 52:1–102, 1 2010.

[4] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2:359–366, 1 1989.

[5] Keller Jordan, Yuchen Jin, Vlado Boza, Jiacheng You, Franz Cesista, Laker Newhouse, and Jeremy Bernstein. Muon: An optimizer for hidden layers in neural networks, 2024.

[6] Jingyuan Liu, Jianlin Su, Xingcheng Yao, Zhejun Jiang, Guokun Lai, Yulun Du, Yidao Qin, Weixin Xu, Enzhe Lu, Junjie Yan, Yanru Chen, Huabin Zheng, Yibo Liu, Shaowei Liu, Bohong Yin, Weiran He, Han Zhu, Yuzhi Wang, Jianzhou Wang, Mengnan Dong, Zheng Zhang, Yongsheng Kang, Hao Zhang, Xinran Xu, Yutao Zhang, Yuxin Wu, Xinyu Zhou, and Zhilin Yang. Muon is scalable for llm training. Technical report, 2 2025.

[7] M. Raissi, P. Perdikaris, and G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2 2019.

[8] Zhao Zhang, Gonglin Yuan, Zhenkai Qin, and Qining Luo. An improvement by introducing lbfgs idea into the adam optimizer for machine learning. *Expert Systems with Applications*, 296, 1 2026.

Author¹ Portfolio Website



Scan this QR code